

Machine learning


SVM

Exercise X


פיתוח:
ד"ר יהונתן שלר
משה פרידמן

מפרידים לינארים
ומושג ה-margin


האם יש רק קו מפריד בין המחלקות?



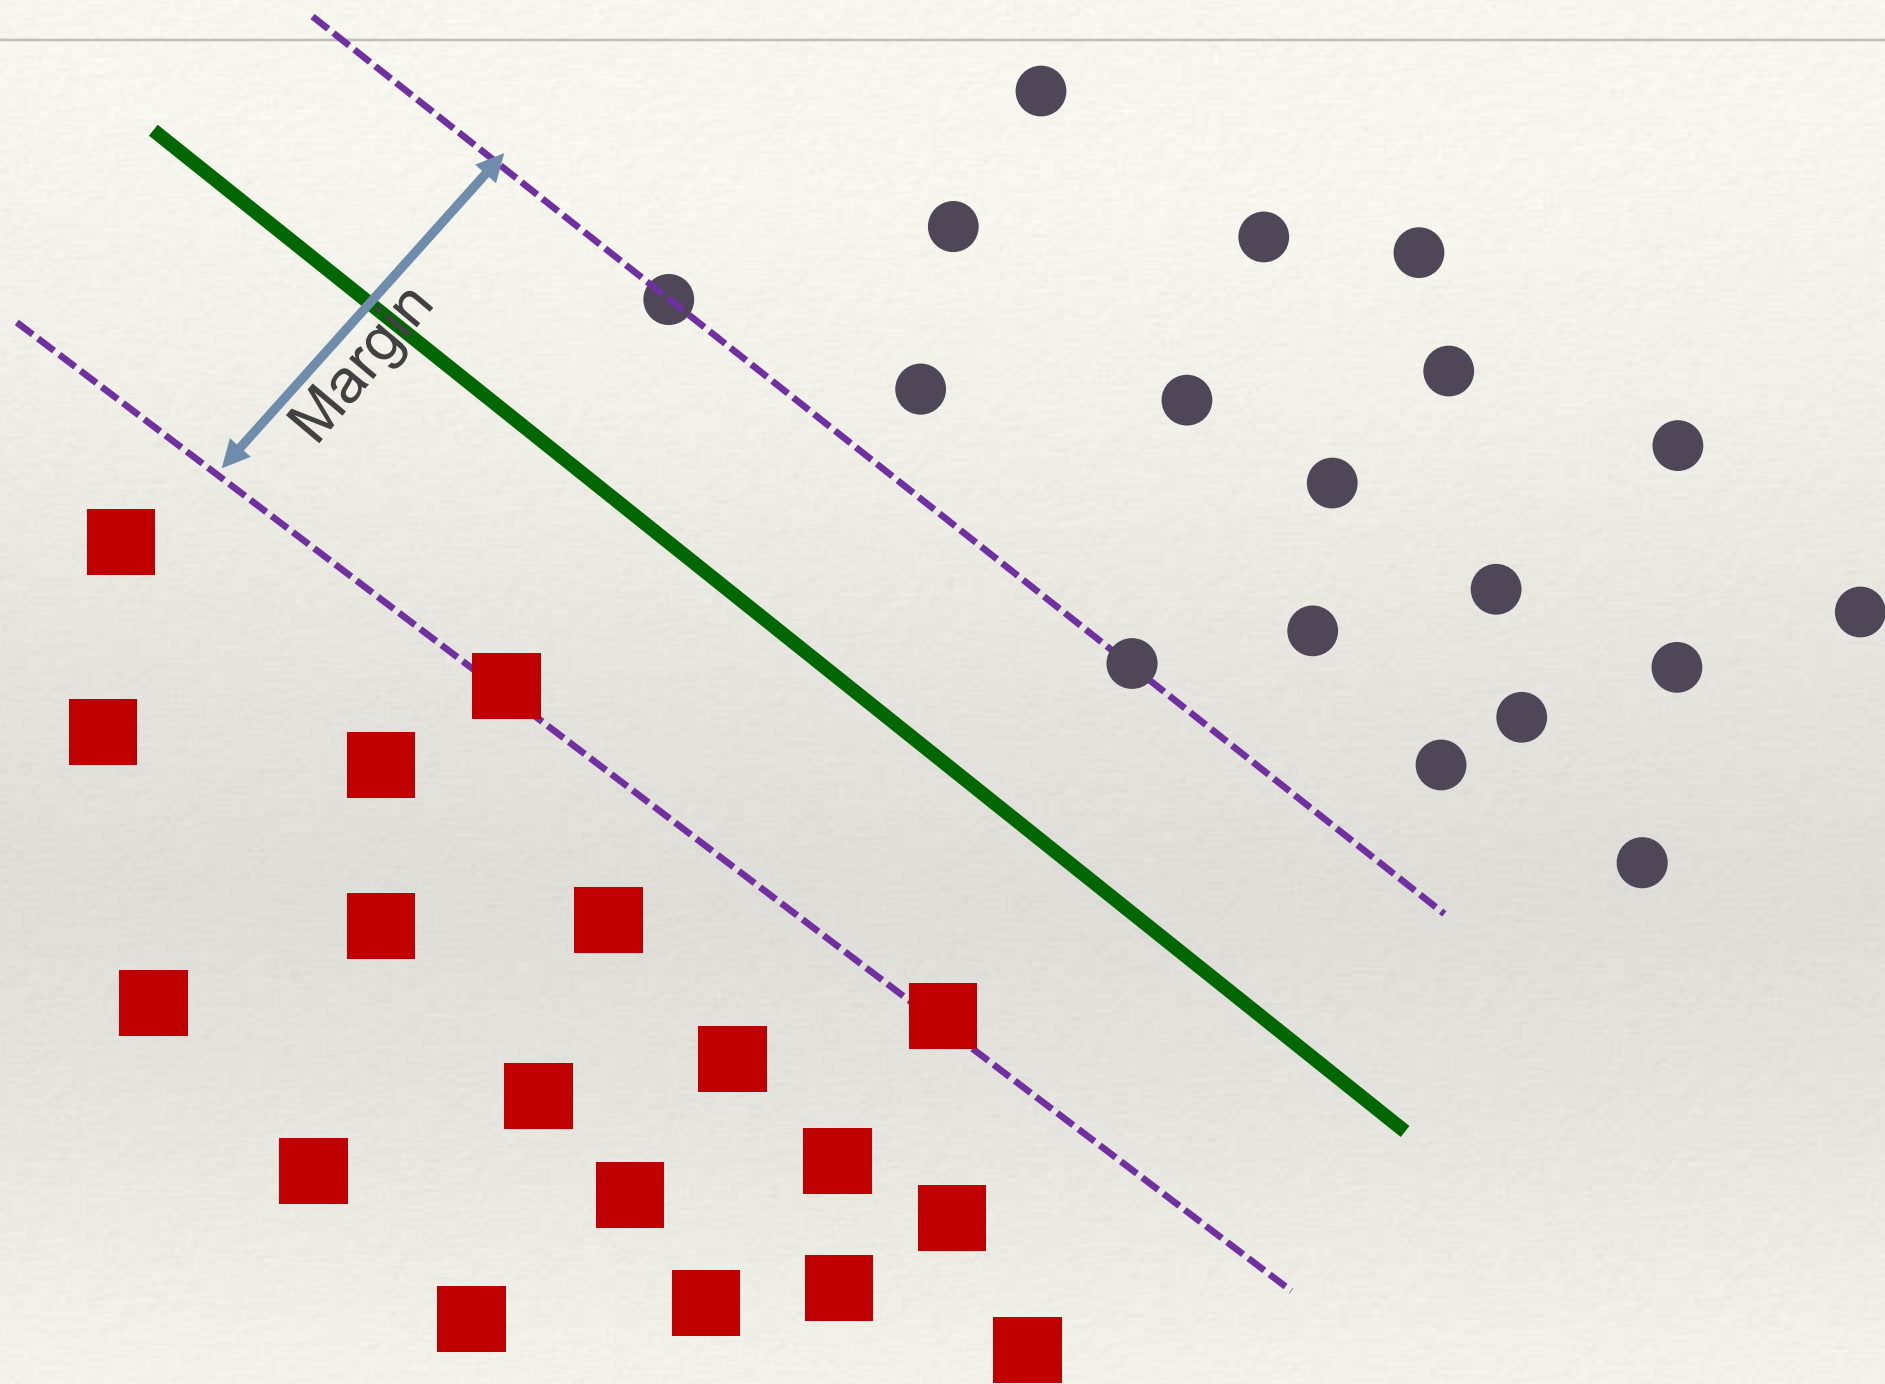
אפשרויות שונות של מפרידים לינארים




אפשרויות שונות של margin



אפשרויות שונות של margin



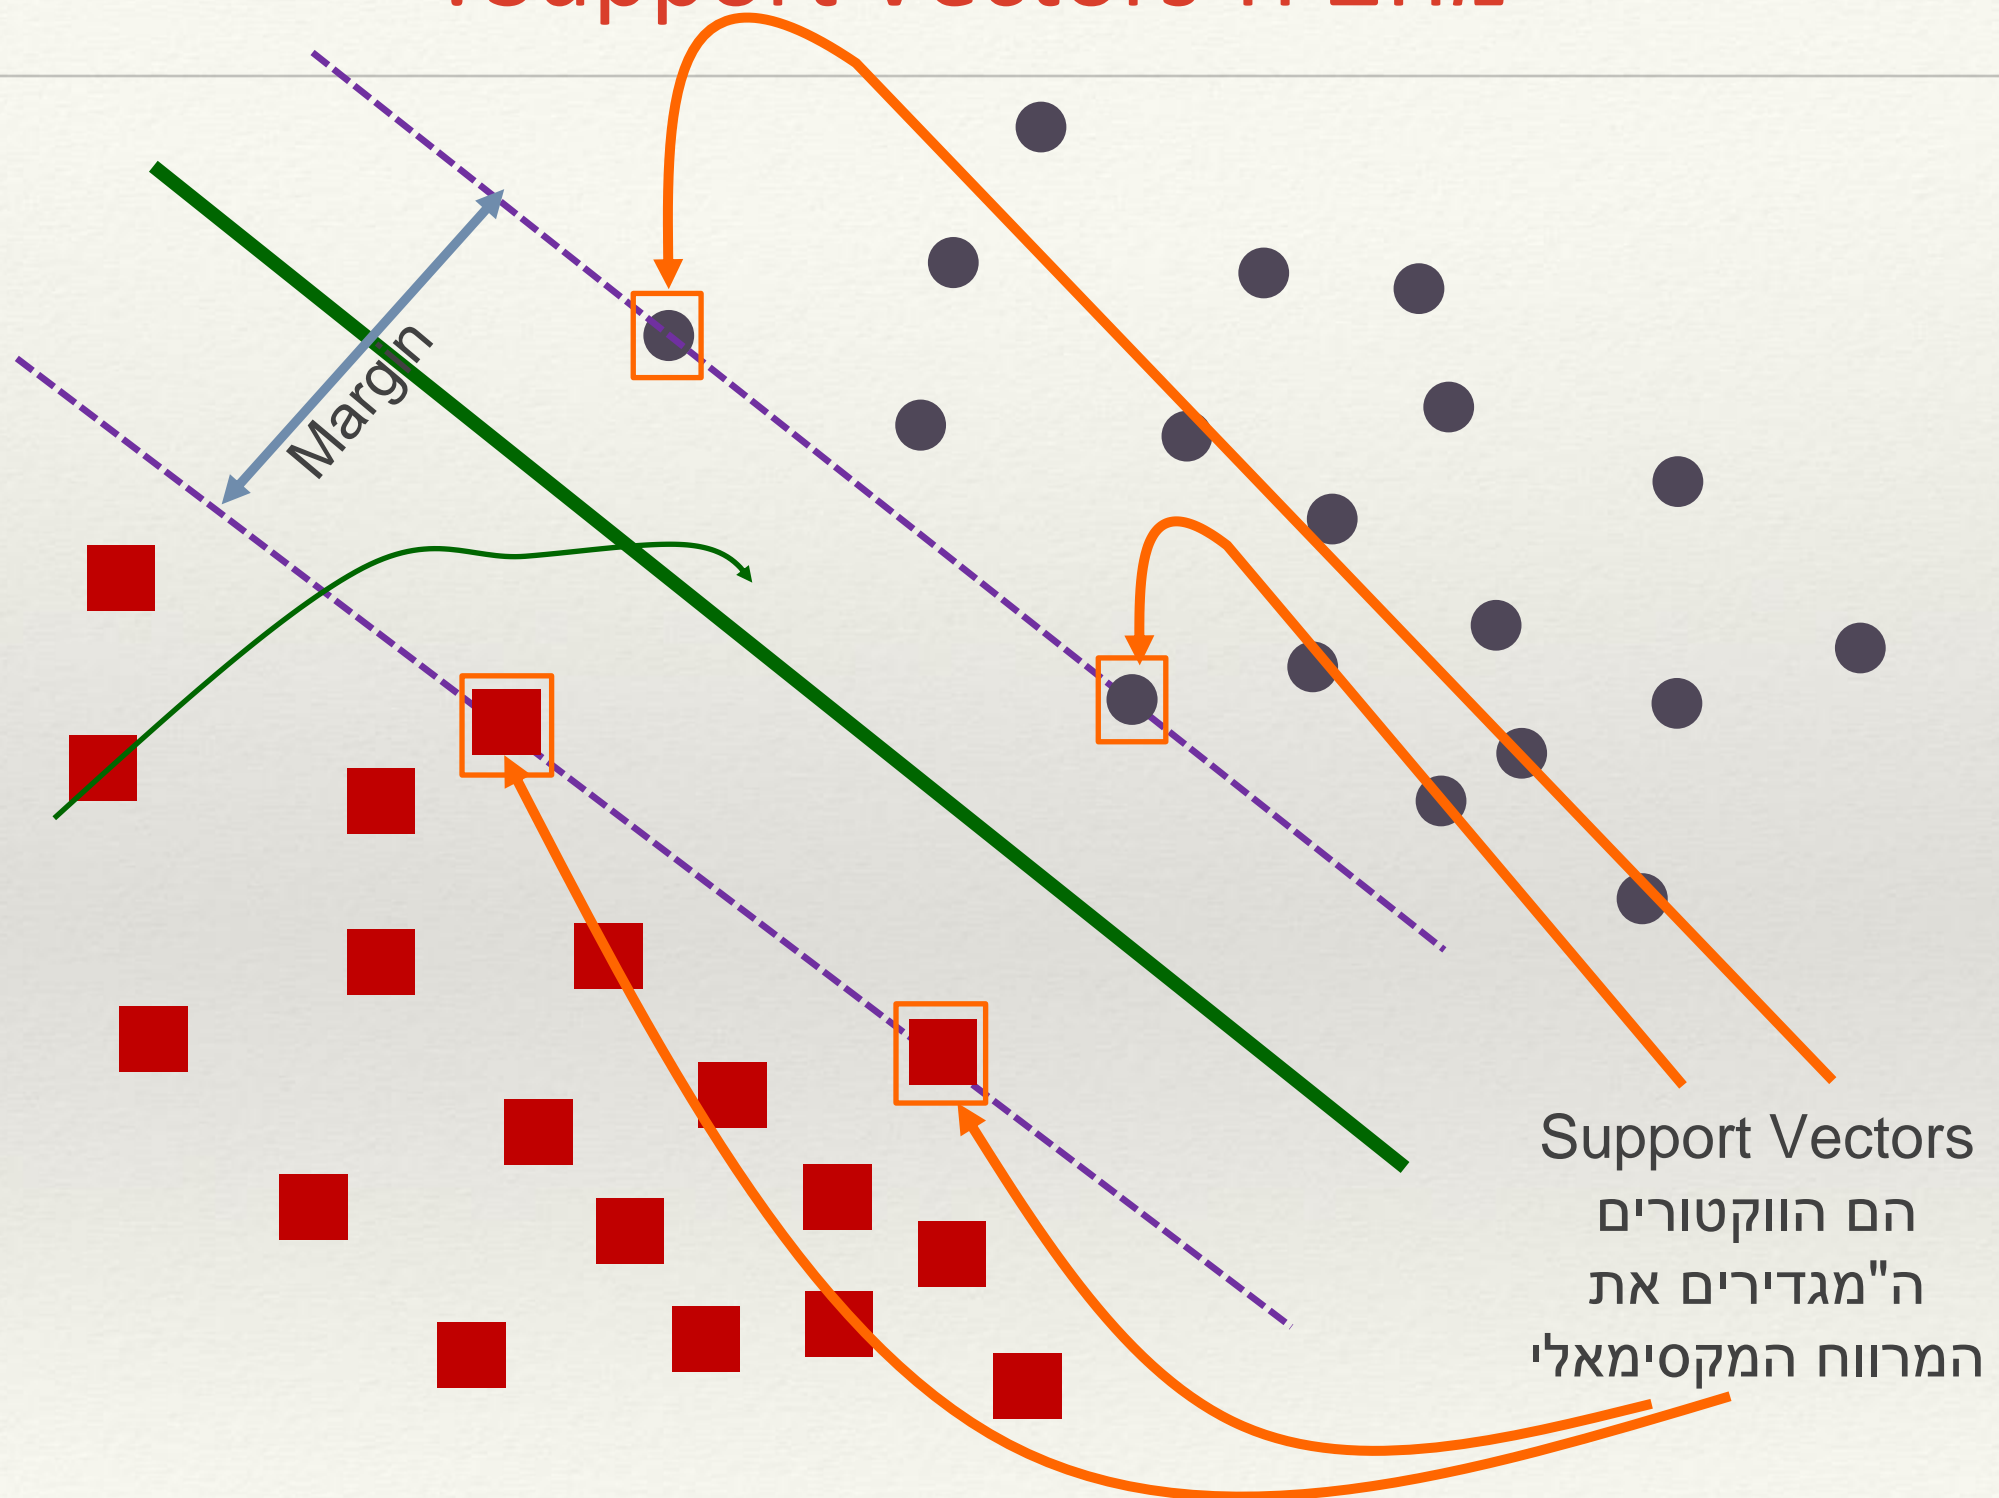
אפשרויות שונות של margin



נחפש את הקו
(hyperplane)
שמייצר לנו את
ה"מרווח" (margin)
המקסימאלי

– Support Vector Machines – SVM

מהם ה-Support Vectors?





מושגים מתמטיים -
וקטורים וסקלרים

מושגים – וקטור (פרספקטיבה גאומטרית) – תזכורת

וקטור (vector) – נסמן $\vec{x}, \vec{y} \in \mathbb{R}^n$

❖ הסבר פיזיקלי/גאומטרי: ישות מתמטית בעלת גודל וכיוון



נורמה של וקטור – הכללה של מושג ה"אורך" (magnitude) – נסמן $\|\vec{x}\|$


מכפלה סקלרית (dot product) של וקטורים – נסמן $\vec{x} \cdot \vec{y}$

$$\vec{x} \cdot \vec{y} = \|\vec{x}\| \cdot \|\vec{y}\| \cdot \cos \theta$$

מבחינה גאומטרית

❖ לכן, מכפלה סקלרית של שני וקטורים היא 0 או "א" הם ניצבים, כיוון ש- $\cos 90 = 0$

כפל הוקטורים $\vec{x} \cdot \vec{y}$ - למה שווה המכפלה
סקר – א. 0; ב. אי אפשר לדעת; ג. 1



$$\vec{x} \cdot \vec{y} = \|\vec{x}\| \cdot \|\vec{y}\| \cdot \cos \theta$$

תשובה א. 0=
מכיוון, שמכפלה סקלרית של
שני וקטורים היא 0 או "א הם
ניצבים, כיוון ש- $\cos 90$
 $\vec{x}, \vec{y} <--- = 0$ ניצבים
(אורתוגונלים)

מושגים – וקטור (פרספקטיבה אלגברית) - תזכורת

וקטור (vector) - נסמן $\vec{x}, \vec{y} \in \mathbb{R}^n$

❖ מבחינה אלגברית: $\vec{x} = (x_1, x_2, \dots, x_n), \vec{y} = (y_1, y_2, \dots, y_n)$

כפל (של וקטור) בסקלר - $\vec{x} \cdot \lambda = \lambda \cdot \vec{x} = (\lambda \cdot x_1, \lambda \cdot x_2, \dots, \lambda \cdot x_n)$

וקטור כמטריצה:

❖ וקטור שורה הוא מטריצה בגודל $1 \times n$ $\vec{x} = [x_1, x_2, \dots, x_n]$

❖ המטריצה המשוכללת (transpose) של וקטור שורה היא וקטור עמודה $n \times 1$

$$\vec{x}^T = [x_1, x_2, \dots, x_n]^T = \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix}$$

תרגיל – כפל וקטור בסקלר

חשבו את וקטור w (לפי הנוסחה שמופיעה למטה)

$\alpha_{1...4}$ - הינם סקלרים, $y_{1...4}$ - הינם סקלרים

$x_{1...4}$ - הינם וקטורים

$$w = \sum_i \alpha_i y_i x_i$$

$$\begin{aligned} & \frac{1}{8} \times -1 \times (1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2}) + \\ & \frac{1}{8} \times +1 \times (1, 1, -\sqrt{2}, 1, -\sqrt{2}, \sqrt{2}) + \\ & \frac{1}{8} \times +1 \times (1, 1, -\sqrt{2}, 1, \sqrt{2}, -\sqrt{2}) + \\ & \frac{1}{8} \times -1 \times (1, 1, \sqrt{2}, 1, \sqrt{2}, \sqrt{2}) = \end{aligned}$$

$$w = (0, 0, -\frac{\sqrt{2}}{2}, 0, 0, 0)$$

$$X1 = (1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2}), \quad y_1 = -1, \quad \alpha_1 = \frac{1}{8}$$

$$X2 = (1, 1, -\sqrt{2}, 1, -\sqrt{2}, \sqrt{2}), \quad y_2 = +1, \quad \alpha_2 = \frac{1}{8}$$

$$X3 = (1, 1, -\sqrt{2}, 1, \sqrt{2}, -\sqrt{2}), \quad y_3 = +1, \quad \alpha_3 = \frac{1}{8}$$

$$X4 = (1, 1, \sqrt{2}, 1, \sqrt{2}, \sqrt{2}), \quad y_4 = -1, \quad \alpha_4 = \frac{1}{8}$$

$$w = \sum_i \alpha_i y_i x_i$$

מושגים – וקטור (פרספקטיבה אלגברית)

וקטור (vector) – נסמן $\vec{x}, \vec{y} \in \mathbb{R}^n$

מכפלה סקלרית (dot product) של וקטורים – נסמן $\vec{x} \cdot \vec{y}$

מבחינה אלגברית – $\langle \vec{x}, \vec{y} \rangle = \sum_{i=1}^n x_i \cdot y_i = x_1 \cdot y_1 + x_2 \cdot y_2 + \dots + x_n \cdot y_n$

❖ בצורה מטריציונית – $\langle \vec{x}, \vec{y} \rangle = \vec{x} \cdot \vec{y}^T = \sum_{i=1}^n x_i \cdot y_i$

תכונות –

❖ חוק הפילוג – $\langle \vec{x}, \vec{y} + \vec{z} \rangle = \langle \vec{x}, \vec{y} \rangle + \langle \vec{x}, \vec{z} \rangle = \vec{x} \cdot (\vec{y} + \vec{z})^T = \vec{x} \cdot \vec{y}^T + \vec{x} \cdot \vec{z}^T$

❖ חוק החילוף – $\langle \vec{x}, \vec{y} \rangle = \langle \vec{y}, \vec{x} \rangle = \vec{x} \cdot \vec{y}^T = \vec{y} \cdot \vec{x}^T$

תרגיל כפל וקטורי

נתונים הוקטורים $\vec{x} = (1,1,1,1,1,1), \vec{w} = (0,0,\frac{-\sqrt{2}}{2},0,0,0)$

חשבו את הכפל הוקטורי: $\vec{w}^T \cdot \vec{x}$

תשובה:

$$0 \cdot 1 + 0 \cdot 1 + \frac{-\sqrt{2}}{2} \cdot 1 + 0 \cdot 1 + 0 \cdot 1 + 0 \cdot 1 = \frac{-\sqrt{2}}{2}$$

מושגים – וקטור (פרספקטיבה אלגברית)

נורמה של וקטור - הכללה של מושג ה"אורך" (magnitude) – נסמן $\|\vec{x}\|$

❖ נורמת L_p – דומה למרחק מיניקובסקי $L_p = \|\vec{x}\|_p$
$$= (\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}}$$

❖ נורמה סטנדרטית (אוקלדית) - נציב $p=2$

$$\begin{aligned} L_2 = \|\vec{x}\|_2 &= \left(\sum_{i=1}^n |x_i|^2 \right)^{\frac{1}{2}} = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} \\ &= \sqrt{x_1 \cdot x_1 + x_2 \cdot x_2 + \dots + x_n \cdot x_n} = \sqrt{\vec{x} \cdot \vec{x}^T} \\ &= \sqrt{\langle \vec{x}, \vec{x} \rangle} \end{aligned}$$

תכונות הנורמה (הסטנדרטית):

❖ $\|\vec{x}\| \geq 0$ - אי שלילי

❖ $\|\lambda \cdot \vec{x}\| = \lambda \cdot \|\vec{x}\|$ - הכפלה בסקלר - מכפילה גם התוצאה בסקלר

❖ $\|\vec{x} + \vec{y}\| \leq \|\vec{x}\| + \|\vec{y}\|$ - מתקיים אי שוויון המשולש

לדו'

$$x=(1,1,1,1,1,1)$$

$$x2=2*x=(2,2,2,2,2,2)$$

נראה ש:

$$\|x2\| = 2 \cdot \|x\|$$

$$\|x\| =$$

$$\sqrt{1*1+1*1+1*1+1*1+1*1+1*1} = \sqrt{6}$$

$$\|x2\| =$$

$$\sqrt{2*2+2*2+2*2+2*2+2*2+2*2} =$$

$$\sqrt{4*(1*1+1*1+1*1+1*1+1*1+1*1)} =$$

$$\sqrt{4} * \sqrt{6} =$$

$$2 * \sqrt{6} = 2 \|x\|$$

תרגיל חישוב נורמה

תרגיל נורמה 1:

נתון הווקטור: $\vec{x}=(2,1)$, חשבו את $||\vec{x}||$ כנורמה הסטנדרטית:


$$\text{תשובה: } \sqrt{2^2 + 1^2} = \sqrt{5}$$

תרגיל נורמה 2:

נתון הווקטור: $\vec{w} = \left(0,0,\frac{-\sqrt{2}}{2},0,0,0\right)$, חשבו את $||\vec{w}||$ כנורמה הסטנדרטית:

$$\text{תשובה: } \sqrt{0^2 + 0^2 + \left(\frac{-\sqrt{2}}{2}\right)^2 + 0^2 + 0^2 + 0^2} = \frac{1}{\sqrt{2}}$$

מרחק נקודה מישר



$$\text{הישר } Ax + By + C = 0 \quad \diamond$$

$$d = \frac{|Ax_1 + By_1 + C|}{\sqrt{A^2 + B^2}}$$


❖ במקרה הכללי – משוואת ה-hyperplane

$$\sum w_i x_i + b = 0$$

$$d = \frac{|wx_s + b|}{\|w\|}$$

מרחק הנקודה x_s מה-hyperplane

תרגיל חישוב מרחק נקודה מhyperplane



נתונה משוואת הישר:

$$\vec{w}^T \cdot \vec{x} = 0$$

נתון הוקטור $\vec{w} = (2, 1)$

נתונה הנקודה $p = (4, 2)$,

מהו מרחק הנקודה p

מהישר הנ"ל.

תשובה: נשתמש בנוסחה:

$$\frac{|\vec{w}^T \cdot \vec{p} + b|}{\|\vec{w}\|}$$

כבר חישבנו $\|\vec{w}\| = \sqrt{5}$

$$\frac{|2 \cdot 4 + 1 \cdot 2 + 0|}{\sqrt{5}} = \frac{10}{\sqrt{5}} = 2\sqrt{5}$$

ניתן לראות גם בעיין ש- p רחוק פי 2 מ- w

איך מחשבים את ה-margin

Point-plane distances from the two margins to the origin:

$$d_+ = \frac{|(w \cdot 0) + b + 1|}{\|w\|}, d_- = \frac{|(w \cdot 0) + b - 1|}{\|w\|}$$

$$\Rightarrow M = \frac{2}{\|w\|}$$

חישוב ה-margin


מודדים את המרחק מהקו
העליו לראשית הצירים
ובאופן דומה לגבי הקו
התחתון

Objective:

$$\max(M) \rightarrow \min(\|w\|^2)$$

s.t.

מקסימיזציה של ה-margin
שקולה למינימיזציה של
הנורמה של וקטור המשקולות



Linear SVM – קבלת החלטה

חישוב w

Calculating w, b :

$$w = \sum_i \alpha_i y_i x_i$$

$$y_i (w \cdot x_i + b) - 1 \geq 0 \quad \forall i$$


The average of the nearest positive support vector and the nearest negative

$$b = -\frac{\max_{y_i=-1} (w \cdot x_i) + \min_{y_i=1} (w \cdot x_i)}{2}$$

Final decision function:

$$f(x) = \text{sign}(w \cdot x + b) = \text{sign}\left(\sum_{i=1}^l \alpha_i y_i x_i \cdot x + b\right)$$

קבועי לגראנז' - $\alpha_i \geq 0$ אם מדובר ב-support vectors, אחרת שווים ל-0



חישוב b , של הקו האמצעי

החלטת סיווג

תרגיל סיווג SVM 1

נתונים:

❖ הטבלה הבאה עם נתוני הנקודות.

❖ קבועי לגראנז' (שכבר עשו עבורים
אופטימיזציה)

Table 1: Training Data

x_1	x_2	y_i	α_i
0.38	0.47	+	65.52
0.49	0.61	-	65.52
0.92	0.41	-	0
0.74	0.89	-	0
0.18	0.58	+	0
0.41	0.35	+	0
0.93	0.81	-	0
0.21	0.10	+	0

חשבו עבורן SVM לינארי, וסווג את הנקודה
(0.5, 0.5)

פתרון (תרגיל סיווג SVM 1)

❖ אנחנו יכולים לראות שיש SV 2

❖ נשתמש במקדמי הלגנרז כדי לחשב את w

❖ איד?

Table 1: Training Data

x_1	x_2	y_i	α_i
0.38	0.47	+	65.52
0.49	0.61	-	65.52
0.92	0.41	-	0
0.74	0.89	-	0
0.18	0.58	+	0
0.41	0.35	+	0
0.93	0.81	-	0
0.21	0.10	+	0

פתרון (תרגיל סיווג SVM 1)

$$w = 65.52(1 \cdot (0.38, 0.47) + -1 \cdot (0.49, 0.61)) = 65.52 \cdot (-0.11, -0.14) \approx (-7.2, -9.17)$$

$$w = \sum_i \alpha_i y_i x_i$$

Table 1: Training Data

x_1	x_2	y_i	α_i
0.38	0.47	+	65.52
0.49	0.61	-	65.52
0.92	0.41	-	0
0.74	0.89	-	0
0.18	0.58	+	0
0.41	0.35	+	0
0.93	0.81	-	0
0.21	0.10	+	0

$$w_1 = \sum_i \alpha_i \cdot y_i \cdot x_{i1} = 65.52 \times 1 \times 0.38 + 65.52 \times -1 \times 0.49 \approx -7.2$$

$$w_2 = \sum_i \alpha_i \cdot y_i \cdot x_{i2} = 65.52 \times 1 \times 0.47 + 65.52 \times -1 \times 0.61 \approx -9.17$$

❖ ועכשיו נחשב את b

❖ The average of the nearest positive support vector and the nearest negative support vector

$$b = -\frac{\max_{y_i=-1}(\mathbf{w} \cdot \mathbf{x}_i) + \min_{y_i=1}(\mathbf{w} \cdot \mathbf{x}_i)}{2}$$

פתרון (תרגיל סיווג SVM 1)

❖ נתון:

x_1	x_2	y_i	α_i
0.38	0.47	+	65.52
0.49	0.61	-	65.52

$$w_1 \approx -7.2$$

$$w_2 \approx -9.17$$

❖ וקיבלנו שערכי המשקולות:

❖ ועכשיו נמצע את הערכים של b עבור הדוגמאות החיוביות והשליליות

$$b = -\frac{\max_{y_i=-1}(\mathbf{w} \cdot \mathbf{x}_i) + \min_{y_i=1}(\mathbf{w} \cdot \mathbf{x}_i)}{2}$$

$$-(((-7.2) \cdot 0.49 + (-9.17) \cdot 0.61) + ((-7.2) \cdot 0.38 + (-9.17) \cdot 0.47)) / 2 \approx 8.084$$

לכן ה hyperplane המפריד המקסימלי הוא:

$$-7.2 \cdot x_1 - 9.17 \cdot x_2 + 8.084 = 0$$

פתרון (תרגיל סיווג SVM 1)

נניח דוגמא חדשה $(0.5, 0.5)$. נציב בנוסחה שמצאנו

$$-7.2 \cdot x_1 - 9.17 \cdot x_2 + 8.084 = 0$$


❖ נקבל

$$-7.2 \cdot 0.5 - 9.17 \cdot 0.5 + 8.084 = -0.101$$

ולכן הדוגמא מסווגת כשייכת לקטגוריה השלילית..

פתרון (תרגיל סיווג SVM 1)

❖ תצוגה של התוצר



תרגיל סיווג SVM 2

❖ נתונים ארבעת הווקטורים הבאים והסיווג שלהם:

$$X_1 = (1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2})$$

$$y_1 = -1$$

$$X_2 = (1, 1, -\sqrt{2}, 1, -\sqrt{2}, \sqrt{2})$$

$$y_2 = +1$$

$$X_3 = (1, 1, -\sqrt{2}, 1, \sqrt{2}, -\sqrt{2})$$

$$y_3 = +1$$

$$X_4 = (1, 1, \sqrt{2}, 1, \sqrt{2}, \sqrt{2})$$

$$y_4 = -1$$

❖ נניח שפתרו עבורינו את בעיית האופטימיזציה של SVM ו"גילו" לנו

$$\alpha_1 = \frac{1}{8}, \alpha_2 = \frac{1}{8}, \alpha_3 = \frac{1}{8}, \alpha_4 = \frac{1}{8}$$

ש:

$$b = 0$$

תרגיל סיווג SVM 2 (המשך)

❖ כיצד נסווג את הווקטור $x_1^{test} = (1,1,1,1,1,1)$

❖ כיצד נסווג את הווקטור $x_2^{test} = (1,1,\sqrt{2},1,-\sqrt{2},-\sqrt{2})$

פתרון (תרגיל סיווג SVM 2)

- זה שכל האלפות שונות מ-0, אומר לנו שכל הווקטורים הם SV
- סיווג דוגמא חדשה x , מקרה לינארי פשוט, ללא קרנל נחשב ראשית את ה- W
- $W = \sum_{i=1}^n y_i \alpha_i x_i$
- נחשב את b במידת הצורך
- ונסווג: $\text{class}(x) = \text{SGN}(Wx - b)$

פתרון (תרגיל סיווג SVM 2) – נתחיל בחישוב w – נראה מוכר?

❖ כלומר, נחשב ראשית את w :

$$\begin{aligned} w &= \sum_i \alpha_i y_i x_i \\ &= \frac{1}{8} \times -1 \times (1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2}) + \\ &\quad \frac{1}{8} \times +1 \times (1, 1, -\sqrt{2}, 1, -\sqrt{2}, \sqrt{2}) + \\ &\quad \frac{1}{8} \times +1 \times (1, 1, -\sqrt{2}, 1, \sqrt{2}, -\sqrt{2}) + \\ &\quad \frac{1}{8} \times -1 \times (1, 1, \sqrt{2}, 1, \sqrt{2}, \sqrt{2}) = \end{aligned}$$

$$w = (0, 0, -\frac{\sqrt{2}}{2}, 0, 0, 0)$$

$$\begin{aligned} X1 &= (1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2}), \quad y_1 = -1, \alpha_1 = \frac{1}{8} \\ X2 &= (1, 1, -\sqrt{2}, 1, -\sqrt{2}, \sqrt{2}), \quad y_2 = +1, \alpha_2 = \frac{1}{8} \\ X3 &= (1, 1, -\sqrt{2}, 1, \sqrt{2}, -\sqrt{2}), \quad y_3 = +1, \alpha_3 = \frac{1}{8} \\ X4 &= (1, 1, \sqrt{2}, 1, \sqrt{2}, \sqrt{2}), \quad y_4 = -1, \alpha_4 = \frac{1}{8} \\ w &= \sum_i \alpha_i y_i x_i \end{aligned}$$

פתרון (תרגיל סיווג SVM 2) – סיווג דוגמא חדשה - לינארי

$$f(x) = \text{sgn}(\sum_i \alpha_i y_i < x_i^T, x > + b) = \text{sgn}(wx + b)$$

$$x_1^{\text{test}} = (1, 1, 1, 1, 1, 1)$$
$$f(x) = \text{sgn}(w^T x + b) = \text{sgn}((0, 0, -\frac{\sqrt{2}}{2}, 0, 0, 0)^T (1, 1, 1, 1, 1, 1) + b)$$

$$= \text{sgn}(0 \times 1 + 0 \times 1 + (-\frac{\sqrt{2}}{2} \times 1) + 0 \times 1 + 0 \times 1 + 0 \times 1 + b) =$$

$$= \text{sgn}(-\frac{\sqrt{2}}{2}) = -1$$

נתון: $b=0$ ולכן $-->$

$$x_2^{\text{test}} = (1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2})$$

$$f(x) = \text{sgn}(w^T x + b) = \text{sgn}((0, 0, -\frac{\sqrt{2}}{2}, 0, 0, 0)^T (1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2}) + b)$$

$$= \text{sgn}(0 \times 1 + 0 \times 1 + (-\frac{\sqrt{2}}{2} \times \sqrt{2}) + 0 \times 1 + 0 \times -\sqrt{2} + 0 \times -\sqrt{2} + b) =$$

$$= \text{sgn}(-1) = -1$$

נתון: $b=0$ ולכן $-->$

כאן אין צורך לחשב. אנו יודעים שזהו SV, עם סיווג שלילי ולכן ברור גם שהצבה שלו במשוואה תיתן -1

hard margin לעומת
soft margin - הסבר

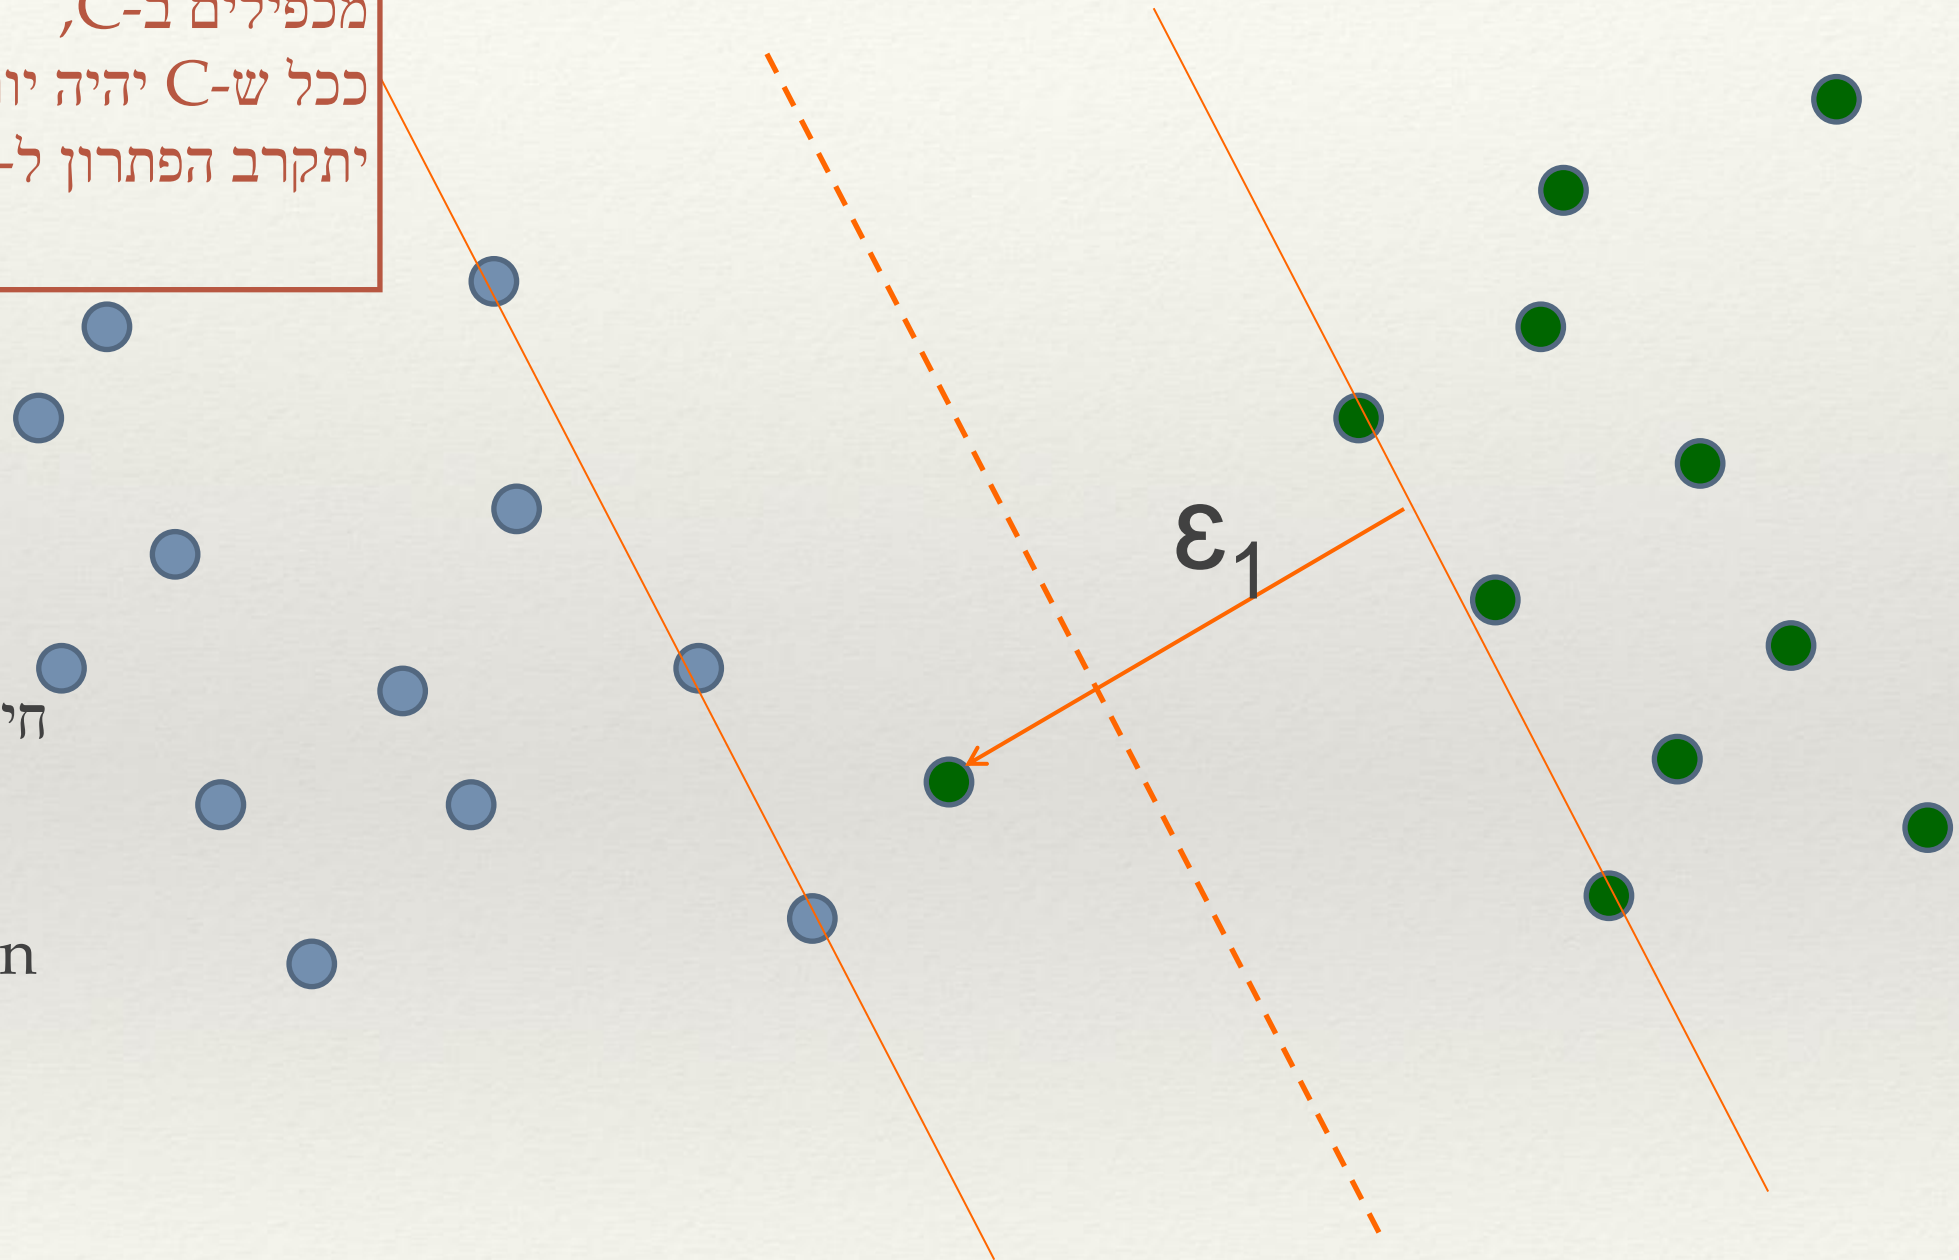
Hard Margin



Soft Margin

Soft margin – מאפשר להעניש
את הדוגמאות שחוצות את ה-
margin בכיוון הלא נכון.
בכמה נעניש?
מכפילים ב- C ,
ככל ש- C יהיה יותר גבוהה,
יתקרב הפתרון ל-hard margin

חישוב הטעות ε_j ,
נמדדת ביחס
למרחק מה-
margin לכיוון
ה"שגוי"



SVM במקרים שאין הפרדה לינארית

תרגיל

❖ פתור את הבעיה הבאה באמצעות SVM עם קרנל לינארי.

❖ נתונה קבוצת האימון הבאה:


$(+1,+1 \mid -1)$

$(-1,+1 \mid +1)$

$(+1,-1 \mid +1)$

$(-1,-1 \mid -1)$

תרגיל



$$X_1 = (+1, +1)$$

$$X_2 = (-1, +1)$$

$$X_3 = (+1, -1)$$

$$X_4 = (-1, -1)$$

$$y_1 = -1$$

$$y_2 = +1$$


$$y_3 = +1$$

$$y_4 = -1$$


מזכיר את בעיית ה-XOR - אין פתרון לינארי לבעיה במימד בו ניתנה

<-- צריך למצוא פתרון לא לינארי


Soft Margin – לעיתים לא מתאים, מדוע?




פתרון ע"י "על-מישור" לא לינארי




כניח שאנו במרחב חד ממדי – בעיה פשוטה




כניח שאנו במרחב חד ממדי – בעיה מסובכת



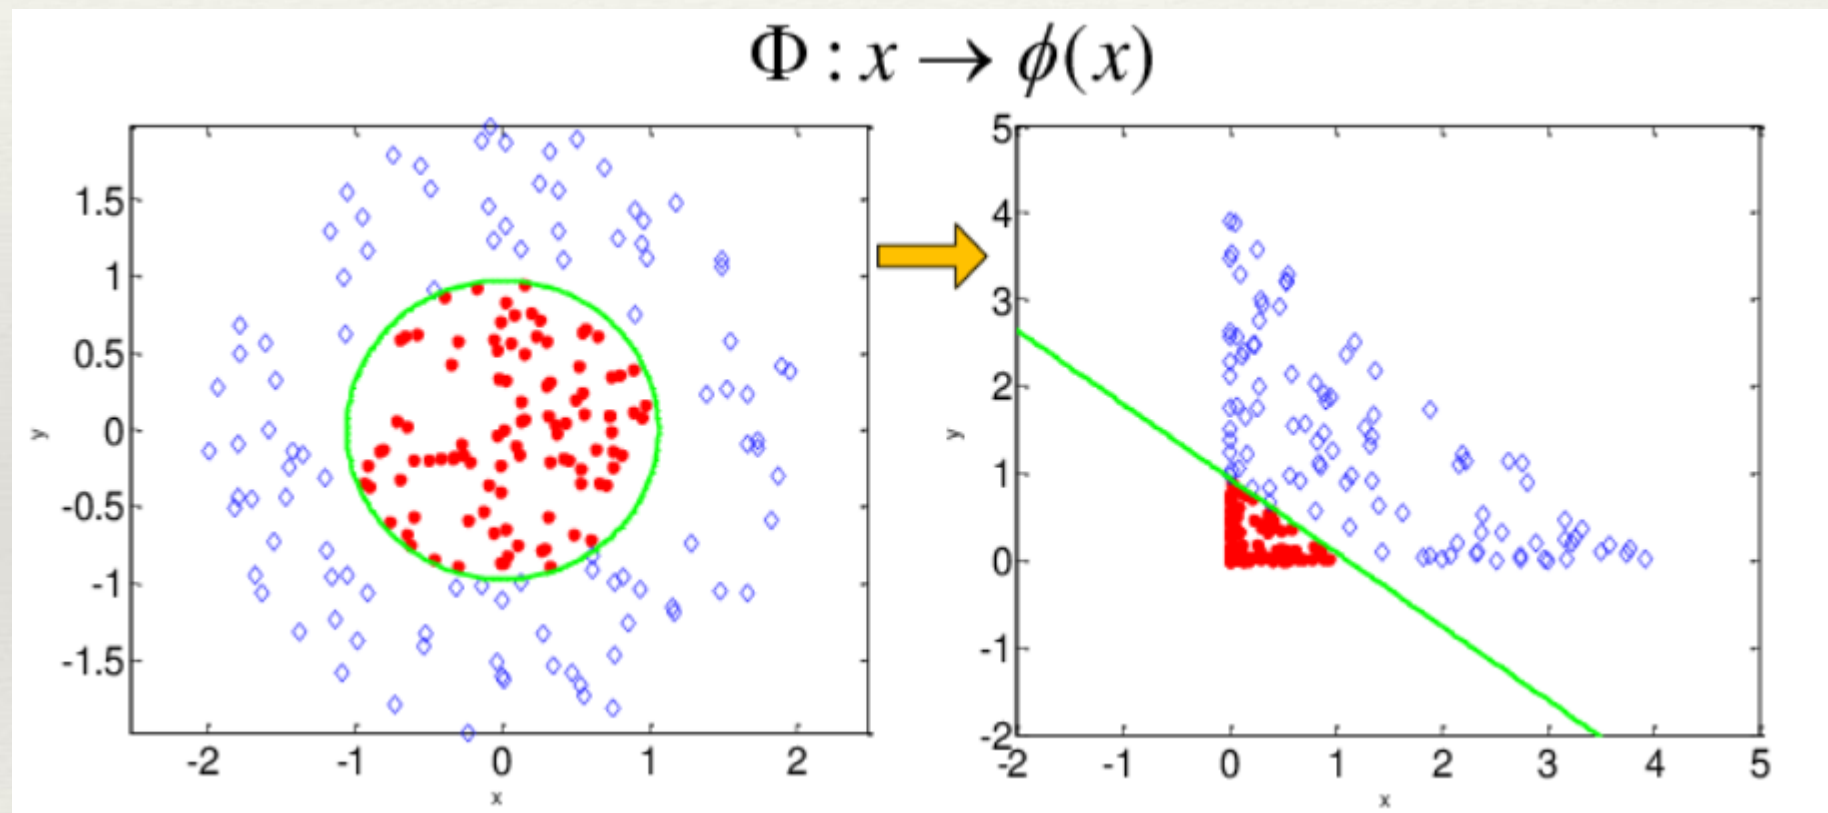
נמיר אותה לבעיה במרחב דו ממדי





פתרון SVM במרחב דו ממדי



SVM with kernels



טרנספורמצית נתונים כפתרון



Note: The feature space is of a higher dimension than the input space

- Computation in the feature space can be costly because it is high dimensional
 - The feature space can be infinite-dimensional!
- The kernel trick comes to rescue

נמפה כל ווקטור למימד הגבוה

$$\theta(x_1, x_2) = [1, x_1^2, \sqrt{2}x_1x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2]$$

$$example_1 = (-1, -1) \longrightarrow \theta(example_1) = (1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2})$$

$$example_2 = (-1, +1) \longrightarrow \theta(example_2) = (1, 1, -\sqrt{2}, 1, -\sqrt{2}, \sqrt{2})$$

$$example_3 = (+1, -1) \longrightarrow \theta(example_3) = (1, 1, -\sqrt{2}, 1, \sqrt{2}, -\sqrt{2})$$

$$example_4 = (+1, +1) \longrightarrow \theta(example_4) = (1, 1, \sqrt{2}, 1, \sqrt{2}, \sqrt{2})$$

$$w = (0, 0, -\frac{\sqrt{2}}{2}, 0, 0, 0)$$

$$y(example_1) = SGN(w \bullet \theta(example_1)) =$$

$$\text{sgn}(0 \times 1 + 0 \times 1 + -\frac{\sqrt{2}}{2} \times \sqrt{2} + 0 \times 1 + 0 \times -\sqrt{2} + 0 \times -\sqrt{2}) = SGN(-1) = -1$$

$$y(example_2) = SGN(w \bullet \theta(example_2)) =$$

$$\text{sgn}(0 \times 1 + 0 \times 1 + -\frac{\sqrt{2}}{2} \times -\sqrt{2} + 0 \times 1 + 0 \times -\sqrt{2} + 0 \times \sqrt{2}) = SGN(1) = 1$$

$$y(example_3) = SGN(w \bullet \theta(example_3)) =$$

$$\text{sgn}(0 \times 1 + 0 \times 1 + -\frac{\sqrt{2}}{2} \times -\sqrt{2} + 0 \times 1 + 0 \times \sqrt{2} + 0 \times -\sqrt{2}) = SGN(1) = 1$$

$$y(example_4) = SGN(w \bullet \theta(example_4)) =$$

$$\text{sgn}(0 \times 1 + 0 \times 1 + -\frac{\sqrt{2}}{2} \times \sqrt{2} + 0 \times 1 + 0 \times \sqrt{2} + 0 \times \sqrt{2}) = SGN(-1) = -1$$

אלו בדיוק

הווקטורים

מהתרגיל

הראשון, רק

שבזכות

טריק הקרנל

חסכנו את

המיפוי

המפורש

למימד

הגבוה